


STANDBY





MẠNG NƠ-RON ĐỒ THỊ

Và tính dễ bị tổn thương trong các ứng dụng thực tế

Trình bày: Bùi Minh Thái
Lê Viết Thành Nhân
Cao Hoàng Lâm

ĐĂNG CAO CƯỜNG



Assignments

Thành Nhân

- Hỗ trợ LaTeX
- Thực nghiệm, thống kê
- Minh họa dữ liệu
- Làm slide
- Tham gia quay chụp
- Phản biện
- Thuyết trình

Minh Thái

- Quản lý dự án
- Quay chụp và chỉnh sửa video
- Hỗ trợ slide
- Thuyết trình
- Hỗ trợ nội dung

Hoàng Lâm

- LaTeX
- Chứng minh lý thuyết các phát hiện
- Hỗ trợ slide
- Thuyết trình

Văn Thương


- Hỗ trợ LaTeX
- Hỗ trợ slide
- Tham gia quay chụp
- Soạn nội dung

Tử Thiên

- Thực nghiệm, thống kê
- Minh họa dữ liệu
- Hỗ trợ slide
- Tìm kiếm nội dung, bài báo

GNN - Graph Neural Network

Mạng xã hội



Giao dịch tài chính



Cấu trúc phân tử




Hệ thống đề cử




GNN

Target node



(a) Input graph


Neural Network



(b) Neighborhood aggregation

GoogLeNet

Convolutional Neural Network



ImageNet Large Scale Visual Recognition Challenge (ILSVRC) winner (2014)




GoogLeNet

???



GoogLeNet

Gibbon


 x

“panda”

57.7% confidence


$+ .007 \times$


 $\text{sign}(\nabla_x J(\theta, x, y))$

“nematode”

8.2% confidence

$=$


 $x + \epsilon \text{sign}(\nabla_x J(\theta, x, y))$

“gibbon”

99.3 % confidence



Nhiệm vụ


Phân tích khía cạnh **bảo mật và độ bền vững** của mô hình trước các nhiễu đối kháng bằng cách **đưa ra, phân tích, và thử nghiệm các thuật toán tấn công.**

Phạm vi

Các phương pháp tấn công chỉ nhắm vào **một đỉnh** nhất định, và chỉ bao gồm việc **thêm/xóa cạnh**

Bối cảnh tấn công là **Grey-box**

Thách thức kỹ thuật



Đóng góp của dự án

- Chỉ ra rằng mô hình phân loại trên đồ thị có thể bị ảnh hưởng bởi nhiễu ngẫu nhiên, đặt ra **nghi vấn về độ ổn định và độ tin cậy** trong thực tế.
- Đề xuất **thuật toán tấn công** hiệu quả, xác định giới hạn tổn thương của các mô hình phân loại đồ thị.
- Cung cấp **phân tích lý thuyết và thực nghiệm** cho thấy mối quan hệ giữa độ dễ bị tổn thương và bậc của node.
- Làm rõ mối liên hệ giữa **độ cứng nhắc (rigidity)** của mô hình, tức khả năng chống lại thay đổi, và **tính dễ bị tổn thương**, thông qua cả **bảng chứng lý thuyết và thực nghiệm**

Thí nghiệm sơ bộ

Tấn công **ngẫu nhiên** (thêm/xóa các cạnh nối với đỉnh mục tiêu một cách ngẫu nhiên) nhằm đánh lừa mô hình phân loại **GCN** (Graph Convolutional Network).

CORA


- 1-labeled (180)
- 0-labeled (2528)
- 10556 cạnh


Tập huấn luyện

- 1-labeled (20)
- 0-labeled (120)

Tập kiểm tra


- 1-labeled (64)
- 0-labeled (936)






Lưu đồ thuật toán **Random Attack**


Development




Deployment



Random Perturb







Structural Gradient-based Attack **(hay Gradient-based Attack)**

Thay đổi cấu trúc
đồ thị
(**cạnh**)

Dựa trên
gradient
(đạo hàm)



Structural Gradient-based Attack
(hay **Gradient-based Attack**)

Structural Gradient-based Attack (hay Gradient-based Attack)


~~Random Attack~~




Xác định chính xác
cạnh tối ưu để thay đổi




Development



Deployment



Attack



Mục tiêu tấn công

dự đoán của GCN khi **chưa bị tấn công**.

ma trận kề

vectơ đặc trưng


$$\hat{y}_i = f_i(\mathbf{A}, \mathbf{X})$$

$$\hat{y}'_i = f_i(\mathbf{A}', \mathbf{X}) = f_i(\mathbf{A} + \Delta\mathbf{A}, \mathbf{X})$$

dự đoán của GCN **đã bị tấn công**.

Sự thay đổi đồ thị (thêm/xóa cạnh)
Đại lượng cần tìm

Đồ thị G



Ma trận kề A


$$\begin{bmatrix} 0 & 1 & 1 & 1 & 0 \\ 1 & 0 & 0 & 0 & 1 \\ 1 & 0 & 0 & 1 & 0 \\ 1 & 0 & 1 & 0 & 1 \\ 0 & 1 & 0 & 1 & 0 \end{bmatrix}$$

Dự đoán ban đầu

$$\begin{cases} \hat{y}_0 = 0 \\ \hat{y}_1 = 0 \\ \hat{y}_2 = 0 \\ \hat{y}_3 = 1 \\ \hat{y}_4 = 0 \end{cases}$$

$$\hat{y}_i = f_i(\mathbf{A}, \mathbf{X})$$

Đồ thị G



**Ma trận
kề A**

$$\begin{bmatrix} 0 & 1 & 1 & 1 & 1 \\ 1 & 0 & 0 & 0 & 0 \\ 1 & 0 & 0 & 1 & 0 \\ 1 & 0 & 1 & 0 & 1 \\ 1 & 0 & 0 & 1 & 0 \end{bmatrix}$$

**Dự đoán
sau khi bị
tấn công**

$$\begin{cases} \hat{y}'_0 = 0 \\ \hat{y}'_1 = 0 \\ \hat{y}'_2 = 0 \\ \hat{y}'_3 = 1 \\ \hat{y}'_4 = 1 \end{cases}$$

$$\hat{y}'_i = f_i(\mathbf{A}', \mathbf{X}) = f_i(\mathbf{A} + \Delta \mathbf{A}, \mathbf{X})$$

(Làm **tăng**)



$$\mathcal{L}_i = \text{NLL}(\hat{y}_i, \hat{y}'_i)$$

Dự đoán **bị thay đổi**

$$\frac{\Delta \mathcal{L}_i}{\Delta \mathbf{A}_{i,j}} \approx \frac{\partial \mathcal{L}_i}{\partial \mathbf{A}_{i,j}}$$



$$\Delta \mathcal{L}_i \approx \frac{\partial \mathcal{L}_i}{\partial \mathbf{A}_{i,j}} \cdot \boxed{\Delta \mathbf{A}_{i,j}} = \frac{\partial \mathcal{L}_i}{\partial \mathbf{A}_{i,j}} \cdot (-2\mathbf{A}_{i,j} + 1)$$

$$\Delta \mathbf{A}_{i,j} = (1 - \mathbf{A}_{i,j}) - \mathbf{A}_{i,j} = \boxed{1 - 2\mathbf{A}_{i,j}}$$

GIẢ SỬ
thay đổi
cạnh
(i,j)



$$\frac{\partial \mathcal{L}_2}{\partial \mathbf{A}_{2,0}} \cdot (-2\mathbf{A}_{2,0} + 1)$$

Sự thay đổi
của hàm loss
tại node 2
nếu thay đổi
cạnh **(2,0)**

**Target
node**

0

1

2

3

4


0

1

2

3

4



$$\frac{\partial \mathcal{L}_2}{\partial \mathbf{A}_{2,3}} \cdot (-2\mathbf{A}_{2,3} + 1)$$

Sự thay đổi
của hàm loss
tại node 2 nếu
thay đổi cạnh
(2,3)

$$\frac{\partial \mathcal{L}_2}{\partial \mathbf{A}_{2,0}} \cdot (-2\mathbf{A}_{2,0} + 1)$$

Sự thay đổi
của hàm loss
tại node 2
nếu thay đổi
cạnh **(2,0)**

**Target
node**

0

1

2

3

4


0

1

2

3

4




$$\frac{\partial \mathcal{L}_2}{\partial \mathbf{A}_{2,3}} \cdot (-2\mathbf{A}_{2,3} + 1)$$

Sự thay đổi
của hàm loss
tại node 2 nếu
thay đổi cạnh
(2,3)


Kỹ thuật cân bằng đối xứng


$$g_{2,3}^2 = g_{3,2}^2 = \frac{1}{2} \left(\frac{\partial \mathcal{L}_2}{\partial \mathbf{A}_{3,2}} + \frac{\partial \mathcal{L}_2}{\partial \mathbf{A}_{2,3}} \right) \cdot (-2\mathbf{A}_{2,3} + 1)$$

Target
node 2




$$g_{2,0}^2 = g_{0,2}^2 = \frac{1}{2} \left(\frac{\partial \mathcal{L}_2}{\partial \mathbf{A}_{0,2}} + \frac{\partial \mathcal{L}_2}{\partial \mathbf{A}_{2,0}} \right) \cdot (-2\mathbf{A}_{2,0} + 1)$$







Greedy





THÍ NGHIỆM & KẾT QUẢ

Thước đo

- Tỷ lệ tấn công thành công (**Attack Success Rate - ASR**)
- Độ sụt giảm độ chính xác (**Accuracy Drop - AD**)
- Tỷ lệ tương đồng về mặt cấu trúc hậu tấn công (**After-perturbation Structural Similarity - ASS**)


Tỷ lệ tấn công thành công (Attack Success Rate - ASR)

Số node **bị tấn công thành công** (phân loại sai nhãn)


$$ASR = \frac{N_{\text{target}}}{N_{\text{success}}} \times 100\%$$

Tổng số node bị tấn công

Tỷ lệ tấn công thành công của thuật toán Gradient-based Attack




Tỉ lệ tấn công thành công tương quan với bậc của đỉnh



Tỉ lệ tán công thành công tương quan với bậc của đỉnh

Biểu diễn $\tilde{\mathbf{x}}_i$ lớp trước

Biểu diễn $\mathbf{x}'_i$ lớp sau



$$\mathbf{x}'_i = \sigma \left(\mathbf{W} \sum_{j \in \mathcal{N}(i) \cup \{i\}} \frac{\mathbf{x}_j}{\sqrt{(d_i + 1)(d_j + 1)}} + b \right)$$

cao

thấp => ít ảnh hưởng

Độ sụt giảm độ chính xác (Accuracy Drop - AD)

Độ chính xác trên tập dữ liệu mà **mỗi đỉnh đều bị tấn công**

$$\text{Accuracy Drop} = \left(\frac{\text{Accuracy}_{\text{clean}} - \text{Accuracy}_{\text{adv}}}{\text{Accuracy}_{\text{clean}}} \right) \times 100\%$$

Độ chính xác trên tập dữ liệu **chưa bị tấn công**

Độ sụt giảm độ chính xác (Accuracy Drop-AD)

Trên tập kiểm tra gốc (chưa bị tấn công), độ chính xác đạt **97.10%**.


Trên tập kiểm tra có đỉnh bị tấn công (số lần thay đổi bằng 5), độ chính xác có thể xuống **14.40%**.

=> Độ sụt giảm độ chính xác của mô hình sau tấn công lên đến **85.17%**.

Mối liên hệ giữa tập dữ liệu huấn luyện, tập dữ liệu kiểm tra, và tỉ lệ tán công thành công

- Tập **0-skewed**: Tỉ lệ số node nhận **0/1** là **6/1**
- Tập **1-skewed**: Tỉ lệ số node nhận **0/1** là **1/6**
- Tập kiểm tra: Toàn bộ node có nhãn là **0**

Mối liên hệ giữa tập dữ liệu huấn luyện, tập dữ liệu kiểm tra, và tỉ lệ tấn công thành công



Mối liên hệ giữa tập dữ liệu huấn luyện, tập dữ liệu kiểm tra, và tỉ lệ tán công thành công

$$\mathcal{L}_i = -\log(\hat{y}_{i,0})$$

lấy đạo hàm

$$g_i = \frac{\partial \mathcal{L}_i}{\partial \hat{y}_{i,0}} = -\frac{1}{\hat{y}_{i,0}}$$

nhỏ

lớn



Tỷ lệ tương đồng về mặt cấu trúc hậu tấn công (After-perturbation Structural Similarity-ASS)

Số node dự đoán trước và sau tấn công **giữ nguyên**

$$ASS = \frac{|\{i \in \mathcal{V} \mid \hat{y}_i = \hat{y}'_i\}|}{|\mathcal{V}|}$$

Tổng số node

Tỷ lệ tương đồng về mặt cấu trúc hậu tấn công (After-perturbation Structural Similarity-ASS)

Thực nghiệm trên **tập kiểm tra** (số lượt thay đổi từ 1 đến 10), chỉ số **ASS** ổn định mức **98%**.

=> Cấu trúc đồ thị **không thay đổi đáng kể**.


=> **Khó phát hiện tấn công**.



THẢO LUẬN VẤN ĐỀ

$$\Delta \mathcal{L}_i \approx \frac{\partial \mathcal{L}_i}{\partial \mathbf{A}_{i,j}} \cdot \Delta \mathbf{A}_{i,j} = \frac{\partial \mathcal{L}_i}{\partial \mathbf{A}_{i,j}} \cdot (-2\mathbf{A}_{i,j} + 1)$$

(Dựa vào đạo hàm của **hàm mất mát** theo **ma trận kề**)




$$\mathcal{L}_i = \text{NLL}(\hat{y}_i, \hat{y}'_i)$$

Tập trung vào làm **sai khác dự đoán**
bằng cách làm **tăng hàm mất mát**

$$\mathcal{L}_i = \text{NLL}(\hat{y}_i, \mathbf{w}_i)$$

Tập trung vào làm **khớp dự đoán**
bằng cách làm **giảm hàm mất mát**

Lĩnh vực tài chính




Anti-fraud models can correctly detect fraudsters on the original graph.



Anti-fraud models will be misled by fake information on the attacked graph.

Node	 Normal  Fraud  Fraud (disguised)	Edge	 Origin  Attacked
------	--	------	---

Hệ thống khuyến nghị



I_1 Recommended for **10** people



I_1 Recommended for **50** people

CORA


- 1-labeled (180)
- 0-labeled (2528)
- 10556 cạnh

Tập huấn luyện

- 1-labeled (20)
- 0-labeled (120)

Tập kiểm tra

- 1-labeled (64)
- 0-labeled (936)



**SUPERVISED
LEARNING**

**UNSUPERVISED
LEARNING**

SEMI-SUPERVISED LEARNING